

动手学大模型应用开发 · 第 3 节

资料检索 与有依据的回答

从资料到证据

主讲：陈思州



课程结构 · 先看全景，再逐类理解做法

先知道每种 RAG 方法解决哪一环，再进入实现细节，避免把新名词当成线性版本号。

01 全景与定义

稳定骨架、发展方向与方法地图

02 共同底座

资料治理、证据单元
与索引路径

03 检索方式

从固定召回到结构化
与动态检索

04 生成核验

上下文组装、引用、
评估与风险

全节始终围绕同一个问题：怎样把可信证据送进模型，并证明回答受这些证据支持。

用户问句不必逐字出现在原文中，检索要找到能回答它的片段。

怎样理解

先看问题：“如何继续昨天的学习？”
再读资料中对 progress.json 的说明。
比较完整问句搜索和关键词搜索。

具体例子

原文说明：读取 progress.json 的下一步计划，
再检查资料版本是否变化。
完整问句没出现，所需信息却在原文里。

检索得到相关文字之后，还要判断它是否包含问题要求的条件与操作。

定义与边界

先把稳定结构讲清，再讨论每个环节有哪些工程实现。




向量库、混合检索和重排是可选实现，不是定义所要求的固定组件。

RAG 从固定管线走向模块化控制

发展总览 · 增加优化位置、模块组合与动态控制

每一层都保留检索增强生成的核心，只是系统可以干预的环节逐步增多。



发展主线是控制范围扩大；简单、稳定的任务仍可能只需要固定管线。

现代 RAG 有五个主要干预位置

模块地图 · 新方法首先改变证据链中的某个位置

识别方法作用的位置，比记忆不断变化的产品名称更稳定。

01	资料治理	解析、权限、版本、元数据与切块
02	查询编排	改写、分解、扩展、路由或保留原问
03	候选检索	稀疏、稠密、结构化或多模态召回
04	选择压缩	融合、重排、去重与上下文压缩
05	生成核验	引用、拒答、支持性检查与评估

现代 RAG 不是单一算法，而是围绕证据链组合模块。

方法选择从问题与失败模式出发

选择标准 · 先识别问题结构，再选择系统复杂度

复杂架构只有在它解决了真实失败模式时才有价值。

任务与失败模式

问题结构、数据形态、证据缺口与运行约束

01 固定或高级 RAG

单跳事实与稳定资料，优化切块、混合召回和重排

02 GraphRAG

关系密集或全局主题，构建图、社区与结构化摘要

03 自适应检索

Agentic RAG 处理多步取证与动态路由，并控制循环、预算与停止条件

04 多模态 RAG

证据包含图像、表格、音频或视频时处理跨模态检索

先用最简单的可验收方案；证据结构或控制需求发生变化时再升级。

证据工程 · 可定位比“搜到一句话”更重要

检索结果要能够回到原文，才能被复核、更新和用于引用。

证据单元

把内容与可追溯信息绑定保存

01 正文

真正用于判断与回答的内容

02 来源

文件、页面、URL 或记录标识

03 边界


行号、段落、页码或时间范围

04 版本

更新时间、提交号或内容指纹

位置证明“在哪里”，版本证明“是哪一版”；两者都不能证明内容本身真实。

切块改变的是返回片段的边界，不应改变可回查的原文。



橙色是两个片段共同保留的第 3 行

三行一块，重叠一行

五行原文得到两个片段：1-3、3-5。
每块保留起止行和正文，便于回查。

再把块大小改成两行

片段变成 1-2、2-3、3-4、4-5。
观察相邻的条件与结论是否被拆开。
边界改变，原文不能随之改变。

重叠可以缓解边界丢信息，也会增加重复证据。块大小需要结合资料结构检查。

治理边界 · 检索能力必须继承资料系统的规则

把知识放进索引会改变它的可发现性，因此数据与权限需要一起管理。

可检索资料

内容、元数据、访问规则和生命周期共同组成知识库

01 来源可信度

记录内容来自哪里，以及谁负责维护

02 访问权限

按当前用户和任务过滤可见内容

03 版本与删除

更新、过期和删除需要同步到索引

04 不可信内容

检索文本是数据，不能改变系统权限与指令

先保证资料可用、可控、可撤回，再讨论检索精度。

TF-IDF 用词频和稀有程度，把文本变成可比较的权重。

怎样理解

本课平滑约定：

$$\text{idf}(t) = \ln((1+N)/(1+\text{df}(t))) + 1$$

$$w(t,d) = \text{tf}(t,d) \times \text{idf}(t)$$

N 是片段数，df 是包含该词的片段数。

具体例子

两段文本：cat cat dog; dog bird。

cat 出现在 1 段：idf $\approx$ 1.4055。

dog 出现在 2 段：idf=1。


第一段 cat 权重为 $2 \times 1.4055 \approx 2.8109$ 。

下一步用余弦比较权重方向。相似度是排序依据，不是答案正确的概率。

查询改写与路由发生在召回之前

检索前处理 · 改善问题与资料表示之间的匹配

查询编排可以减少表达差异，但必须保留原始意图并限制改写范围。



查询编排改善召回入口；任何改写都要能够回到原问题核验。

稀疏检索 · 词项是否匹配


把查询和片段映射为词项权重向量，再按相似度排列候选。

01	切分词项	保留可检索的词、符号或短语
02	计算权重	TF-IDF 突出具有区分度的词项
03	比较方向	余弦相似度衡量向量接近程度
04	输出名次	按分数返回前 k 个候选片段

适合精确名称与稀有词；相似度用于排序，不代表事实正确率。

稠密检索 · 含义是否接近

查询与片段使用同一套兼容编码规则，才能在同一向量空间中比较。



语义相近不等于事实支持；模型选择必须结合语言、领域和检索评估。

先确认向量和原文对应，再计算排序，避免拿错版本的数值解释资料。

怎样理解

检查编码器名称、revision 与输入哈希。
查看问题向量和片段向量的形状。
计算点积并按分数降序读回原文。

具体例子

每行向量都应对应同一条已记录文本。
修改文本却沿用旧向量，会造成错配。
取前 k 条后，逐条指出它为何相关。

随课向量是真实编码的保存结果。重新生成时，应记录编码器版本与输入哈希，方便复核。

上下文化检索 · 在索引阶段补回被切块丢失的语境


片段保留原文，同时增加一段可核验的文档级定位说明。

01	读取文档	识别主题、章节、主体与时间范围
02	生成语境	为当前片段补充简短定位说明
03	保留原文	语境与原始片段绑定，而非改写原文
04	双路索引	用于词项与语义检索
05	检索重排	召回后继续检查相关性与支持性

上下文化检索修复片段失去语境的问题；原文仍是最终核验依据。

组合检索 · 先召回，再统一排序

不同检索器保留各自的评分体系，融合层只接收候选与名次。



混合检索改善候选覆盖；证据是否支持问题仍需后续判断。

Reciprocal Rank Fusion • 比较名次而非原始分数

每一路保留自己的评分规则，融合层使用 rank 计算可比较的贡献。


01	各路名次	每个检索器输出候选名次
02	名次贡献	候选越靠前，倒数排名贡献越大
03	贡献累加	同一候选汇总多路排名贡献
04	融合排序	按融合分数形成统一候选列表

RRF 解决的是分数尺度不一致；它不能证明前列候选一定支持答案。

重排只精炼已经召回的候选

两阶段检索 · 召回负责覆盖，重排负责前列质量


先用高效检索器缩小范围，再把更昂贵的联合判断用于少量候选。



候选中没有的证据，重排器无法凭空恢复。

图检索 · 从片段相似度扩展到实体关系与全局主题

图结构让系统能够沿关系寻找证据，也能利用社区摘要回答整体性问题。



GraphRAG 用更高的索引与维护成本，换取关系检索和全局聚合能力。

层次关系 · 方法、表示、语义与产品需要分开

同一个企业知识系统可以同时使用这些层次，但它们承担不同职责。

企业知识系统

围绕检索、表示、治理和使用场景组合能力

01 GraphRAG

利用关系、邻域或社区摘要寻找证据

02 知识图谱

把实体、关系与事实组织成可查询结构

03 本体

定义共享概念、关系语义与形式约束

04 知识产品


Wiki、搜索或助手把底层能力交付给用户

GraphRAG 偏检索，知识图谱偏表示，本体偏语义与治理。

Agentic RAG 让检索成为可迭代行动

检索控制 · 从一次管线到按证据质量循环

控制器依据问题与证据状态，决定检索、选源或重试。



Agentic RAG 的新增价值是动态控制检索，而不是把所有查询都变成无限循环。

条件生成 • 把输入结构化，而不是只堆文本

生成模型需要知道问题是什么、哪些材料可用、每段来自哪里，以及证据不足时怎样停止。

证据包

把问题、证据与约束作为一次可审计输入

01 问题

当前需要回答的任务

02 证据正文

本轮检索与排序后的片段

03 来源位置

用于引用和回查的元数据

04 回答约束

仅依证据回答，允许说明不足

资料不足是一种合法结果；补写不存在的事实不是。

生成模型应收到本次实际检索的原文，并知道证据不足时如何回答。

怎样理解

打印发送的用户问题与 evidence 正文。
查看保存的 DeepSeek 回答。
将每个引用映射到本次返回的片段。

具体例子

核验示例：“截止周五”。
先找到被引用的片段。
核对是否周五截止，以及特殊条件。
若无答案，允许返回“资料不足”。

位置合法只通过第一层检查。事实、数字和条件仍要与原文逐句对应。

回答错误要沿证据链逐层定位

故障定位 · 先查证据链，再查表达层

每一层都应保存可观察输出，才能判断错误最早从哪里出现。

01	源资料	事实是否存在且版本正确
02	切块索引	证据是否被完整保存和更新
03	检索排序	支持性证据是否进入前列候选
04	上下文	候选是否实际进入本次请求
05	生成回答	主张是否忠于证据与约束

修复最早失效的环节；不要用提示词掩盖索引或检索问题。

保留合法引用，故意改错一个数字，检验自己的检查是否足够。

怎样理解

取一条已有真实位置的回答。
只替换其中的日期或数量。
分别检查引用有效性和事实一致性。

具体例子

引用：rules.md 的实际片段。
原文：“周五截止”。
改错回答：“周一截止”。
引用检查可通过，事实检查应失败。

移除答案片段后，检索仍可能返回相关但无答案的文字。非空结果不等于有依据。

本节建立了一条可核验的证据链

回到学习目标

一个可靠的检索增强系统，需要让证据从资料源一直可追溯到最终主张。



全景与定义

固定管线逐步增加模块组合与动态控制



共同底座

资料治理、证据单元与索引路径决定可用范围



检索方式

按问题结构选择稀疏、稠密、图或迭代检索



生成核验

证据约束回答，逐层定位失败

先理解方法地图，再按真实失败模式组合模块，并用评估证明改进。

本节关于 RAG 定义、检索方法与评估边界主要参考以下论文和官方资料。

- | | | |
|-----|---------------------------------|---|
| [1] | Lewis, Patrick, et al. | Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks
NeurIPS 2020 · arXiv:2005.11401 |
| [2] | Gao, Yunfan, et al. | Retrieval-Augmented Generation for Large Language Models: A Survey
arXiv:2312.10997 |
| [3] | Cormack, Gordon V., et al. | Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods
SIGIR 2009 |
| [4] | Asai, Akari, et al. | Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection
ICLR 2024 |
| [5] | Yan, Shi-Qi, et al. | Corrective Retrieval Augmented Generation
arXiv:2401.15884 |
| [6] | Microsoft Research | GraphRAG
microsoft.com/en-us/research/project/graphrag |
| [7] | Anthropic | Contextual Retrieval
anthropic.com/engineering/contextual-retrieval |
| [8] | Manning, Christopher D., et al. | Introduction to Information Retrieval
Cambridge University Press, 2008 · nlp.stanford.edu/IR-book |